Construire un RAG sur GCP

Vertex AI RAG Engine · Gemini · Cloud Run

Le problème

- Les LLM ignorent vos données privées
- Hallucinations sur les sujets pointus
- Besoin de citer les sources

L'architecture

- Cloud Storage → RAG Engine (chunks + embeddings)
- Agent ADK sur Cloud Run
- Gemini avec outil de retrieval

Mise en œuvre

- Terraform pour l'infrastructure
- Cloud Run Job de synchronisation
- CI/CD GitHub Actions + Workload Identity

Points de vigilance

- Quotas d'embedding
- Coût du stockage vectoriel
- Sécurité : VPC-SC et Model Armor